

1) PsychApp Documento Marco Arquitectura y Objetivos

v0.1.

miércoles, 22 de julio de 2026 11:09

PSYCHAPP

Documento marco de arquitectura y objetivos

Base evolutiva para el desarrollo de una aplicación de salud mental con inteligencia artificial

Naturaleza del documento

Este texto no define un producto final ni congela decisiones de diseño. Establece un marco común de visión, objetivos, arquitectura, seguridad, investigación y fases de desarrollo. Debe utilizarse como mapa de trabajo vivo, sujeto a validación clínica, técnica, ética y con usuarios.

Campo	Definición
Versión	0.1 — documento de base
Estado	Borrador estructural para iteración
Alcance	Arquitectura conceptual, objetivos, módulos, flujos y hoja de ruta
Fuera de alcance	Diagnóstico automatizado, decisión clínica autónoma, producto regulatorio terminado
Fuente de partida	Documentos y capturas aportados por el autor, integrados y reorganizados
Audiencia	Promotor del proyecto, equipo clínico, producto, ingeniería, datos, seguridad y evaluación

Julio de 2026

0. Resumen ejecutivo

PsychApp se concibe como una plataforma de acompañamiento y monitorización longitudinal en salud mental que combina conversación, datos autorizados por la persona usuaria, memoria estructurada y análisis temporal. Su propósito no es sustituir la evaluación profesional ni emitir diagnósticos, sino ayudar a comprender patrones, detectar cambios relevantes, reforzar factores protectores y facilitar una intervención humana más temprana cuando proceda.

La tesis central del proyecto es que el valor clínico potencial no reside en una inferencia puntual de personalidad, sino en la comparación continuada de la persona consigo misma. Por tanto, el sistema debe priorizar el estado dinámico, la trayectoria individual, la incertidumbre, la explicabilidad y el control del usuario sobre sus datos.

Principio rector

La aplicación debe responder a tres preguntas de forma prudente: ¿qué está cambiando?, ¿qué evidencia respalda esa observación? y ¿qué acción proporcionada y segura puede ayudar ahora?

Eje	Decisión marco
Orientación	Prevención, autoconocimiento y apoyo; no diagnóstico ni tratamiento autónomo.
Unidad de análisis	La trayectoria individual y sus desviaciones respecto a un baseline personal.
Datos	Mínimos, consentidos, trazables, revocables y segmentados por finalidad.
IA	Asistente explicable y supervisable; no autoridad clínica.
Riesgo	Sistema escalonado con intervención humana y protocolos específicos.
Desarrollo	Iterativo: descubrimiento, prototipo, validación, piloto y posible producto.

1. Cómo utilizar este documento

Este documento es una brújula de desarrollo. Define una arquitectura objetivo suficientemente concreta para alinear equipos, pero deliberadamente evita fijar tecnologías, umbrales, modelos o flujos clínicos que todavía requieren investigación y validación.

1.1 Decisiones que sí establece

- La separación entre perfil basal, estado dinámico, señales observadas y conclusiones inferidas.
- La necesidad de consentimiento granular, trazabilidad y minimización de datos.
- Una arquitectura modular que permita sustituir modelos sin rehacer el producto.
- La obligación de expresar incertidumbre y evidencias contribuyentes.
- La existencia de rutas de seguridad y escalado humano independientes del motor generativo.
- La validación por fases antes de cualquier afirmación clínica o uso asistencial.

1.2 Decisiones deliberadamente abiertas

- Población clínica inicial y trastornos prioritarios.
- Fuentes de datos que se integrarán en la primera versión.
- Instrumentos psicométricos concretos y frecuencia de evaluación.
- Algoritmos finales de detección, predicción y personalización.
- Modelo de despliegue, infraestructura y proveedores.
- Clasificación regulatoria y estrategia de certificación, si llegara a aplicar.

1.3 Ciclo de revisión

Momento	Pregunta de revisión	Salida
Tras descubrimiento	¿El problema y la población están bien delimitados?	Revisión de visión y alcance.
Tras prototipo	¿La interacción es comprensible y segura?	Revisión de experiencia y guardrails.
Tras estudio retrospectivo	¿Las señales tienen valor y estabilidad?	Revisión del modelo analítico.
Tras piloto	¿Existe utilidad clínica y aceptabilidad?	Decisión de continuidad o rediseño.
Antes de escalar	¿La gobernanza, seguridad y evidencia son suficientes?	Go/no-go documentado.

2. Visión, problema y propuesta de valor

2.1 Problema que se pretende abordar

La atención en salud mental suele disponer de observaciones discontinuas: entrevistas separadas por semanas o meses, autorregistros incompletos y señales tempranas que sólo se reconocen retrospectivamente. Al mismo tiempo, la vida cotidiana genera información conductual y contextual que podría ayudar a reconstruir cambios de rutina, sueño, actividad, interacción, lenguaje y funcionamiento.

El reto no es recopilar más datos, sino convertir señales heterogéneas y ruidosas en información útil, comprensible y proporcionada, evitando vigilancia invasiva, falsas certezas, sobrereacción y medicalización de variaciones normales.

2.2 Propuesta de valor

Actor	Valor potencial
Persona usuaria	Mayor conciencia de patrones propios, señales tempranas y factores protectores; control explícito sobre sus datos.
Profesional	Resumen longitudinal, hipótesis transparentes y reducción del tiempo dedicado a reconstruir retrospectivamente la evolución.
Equipo cuidador autorizado	Señales y planes acordados, sólo dentro de límites consentidos.
Investigación	Infraestructura para estudiar trayectorias individualizadas y utilidad de señales digitales con gobernanza adecuada.
Producto	Plataforma modular capaz de crecer desde autocuidado hasta escenarios clínicos validados.

2.3 Hipótesis fundamentales

- Los cambios intraindividuales son generalmente más informativos que la comparación con promedios poblacionales.
- Las combinaciones y secuencias de señales pueden ser más útiles que una anomalía aislada.
- La incertidumbre explícita mejora la seguridad y la confianza.
- Las recomendaciones deben derivarse de mecanismos plausibles y preferencias del usuario, no sólo de una puntuación de riesgo.
- La integración con profesionales debe diseñarse desde el principio, aunque la primera fase sea de autocuidado.

3. Principios clínicos, éticos y de producto

Principio	Implicación operativa
Primero, no dañar	Toda funcionalidad debe evaluarse por riesgos de alarma, estigma, dependencia, invasión de privacidad y retraso de atención profesional.
Autonomía informada	El usuario decide qué datos aporta, para qué finalidades y durante cuánto tiempo. La revocación debe ser sencilla.
Proporcionalidad	La intensidad del análisis y de la respuesta debe corresponder al nivel de evidencia y riesgo.
No diagnóstico por defecto	El lenguaje del sistema describe observaciones, cambios e hipótesis; no atribuye trastornos ni sustituye juicio clínico.
Explicabilidad útil	Cada conclusión relevante debe mostrar señales, periodo, comparación, calidad de datos y grado de confianza.
Equidad	El rendimiento debe analizarse por subgrupos y contextos; las ausencias de datos no deben interpretarse como patología.
Privacidad por diseño	La arquitectura reduce, separa y protege datos desde el origen, no como añadido posterior.
Humano en el circuito	Las situaciones de riesgo y las decisiones asistenciales requieren rutas humanas y protocolos verificables.
Evaluación continua	Los modelos, prompts y umbrales se tratan como componentes clínicamente sensibles con versionado y auditoría.

4. Alcance funcional por niveles

Para evitar que el proyecto intente resolver simultáneamente autocuidado, predicción clínica, gestión asistencial y dispositivo médico, se propone una progresión por niveles de madurez.

Nivel	Finalidad	Funciones indicativas	Condición de avance
A. Autoconocimiento	Ayudar a observar rutinas y bienestar.	Check-ins, diario, tendencias descriptivas, recordatorios, planes personales.	Usabilidad, seguridad y comprensión.
B. Prevención personalizada	Identificar desviaciones del patrón individual.	Baseline, anomalías, factores protectores, alertas privadas graduadas.	Validez analítica y baja tasa de daño.
C. Colaboración clínica	Compartir resúmenes y planes con profesionales.	Panel clínico, exportación, comentarios, objetivos compartidos.	Aceptabilidad profesional y gobernanza.
D. Apoyo predictivo validado	Estimar probabilidad de eventos definidos.	Modelos validados, calibración, umbrales por contexto.	Evidencia prospectiva y marco regulatorio.

Límite inicial recomendado
La primera iteración debería situarse entre los niveles A y B: descripción longitudinal, personalización y seguridad. La predicción clínica debe considerarse una línea de investigación, no una promesa inicial.

5. Usuarios, roles y escenarios

5.1 Roles

Rol	Permisos y responsabilidades
Usuario principal	Controla consentimiento, fuentes de datos, preferencias, planes y compartición.
Profesional autorizado	Accede a información seleccionada; valida o corrige interpretaciones; define planes cuando el uso sea clínico.
Contacto de apoyo	Recibe únicamente comunicaciones previamente acordadas y bajo reglas explícitas.
Administrador clínico	Gestiona protocolos, contenidos, cohortes y revisión de incidentes, sin acceso indiscriminado.
Equipo de datos/ML	Trabaja con datos minimizados y entornos segregados; no accede a identidades salvo necesidad justificada.
Auditor/seguridad	Revisa trazabilidad, accesos, incidentes y cumplimiento.

5.2 Escenarios prioritarios

Onboarding progresivo

La persona define objetivos, límites, fuentes de datos y un primer mapa de bienestar sin interrogatorio exhaustivo.

Check-in breve

El sistema recoge estado subjetivo y contexto, lo compara con tendencias y devuelve una síntesis prudente.

Revisión semanal

Se presentan cambios, posibles desencadenantes, factores protectores y acciones acordadas.

Desviación relevante

Una combinación de señales supera criterios internos; se solicita confirmación y se activa una respuesta graduada.

Preparación de consulta

Se genera un resumen seleccionable: evolución, síntomas reportados, adherencia, sueño, eventos y preguntas pendientes.

Plan preventivo

Usuario y profesional definen señales tempranas, acciones, contactos y límites de automatización.

6. Modelo conceptual del sistema

La arquitectura se organiza alrededor de una separación estricta entre datos observados, variables derivadas, inferencias y acciones. Esta separación permite auditar errores, sustituir componentes y evitar que una interpretación del LLM se convierta en “hecho” persistente.

Flujo conceptual
Fuentes autorizadas → normalización → variables derivadas → baseline y contexto → detección temporal → estimación con incertidumbre → explicación → recomendación o escalado → retroalimentación.

Capa	Responsabilidad	Ejemplo
Observación	Registrar datos o autorreportes con procedencia y tiempo.	Horas de sueño reportadas; eventos de calendario.
Derivación	Transformar observaciones en métricas reproducibles.	Regularidad circadiana; frecuencia de interacción.
Contexto	Representar circunstancias que modifican la interpretación.	Turnos laborales; viaje; enfermedad somática.
Baseline	Estimar rangos personales y estacionalidad.	Rango habitual de sueño por día de semana.
Detección	Identificar cambios, secuencias o estados.	Caída sostenida de actividad respecto al baseline.
Inferencia	Proponer hipótesis y nivel de confianza.	Posible deterioro funcional, confianza baja.

Acción	Seleccionar una intervención proporcionada.	Check-in adicional; revisar plan; contactar profesional.
--------	---	--

7. Arquitectura funcional de alto nivel

Módulo	Responsabilidad
1. Identidad y consentimiento	Autenticación, preferencias, permisos por fuente/finalidad, revocación y registro de versiones.
2. Ingesta y conectores	Recepción de autorregistros, wearables, calendario, tareas u otras fuentes autorizadas.
3. Normalización temporal	Zona horaria, calidad, ventanas, eventos, ausencias y resolución de duplicados.
4. Feature Store clínico-conductual	Variables derivadas versionadas, con procedencia y reglas de cálculo.
5. Memoria longitudinal	Perfil basal, episodios, planes, preferencias y hechos confirmados.
6. Motor analítico	Tendencias, estacionalidad, anomalías, cambios de estado y secuencias.
7. Motor de riesgo y seguridad	Reglas deterministas, modelos probabilísticos, calibración y escalado.
8. Orquestador LLM	Conversación, síntesis, herramientas y generación condicionada por políticas.
9. Motor de recomendaciones	Intervenciones seleccionadas por objetivo, evidencia, preferencias y seguridad.
10. Interfaces	Aplicación del usuario, panel profesional, administración y exportación.
11. Auditoría y observabilidad	Logs, calidad, drift, incidentes, explicaciones y revisión humana.

7.1 Separación crítica entre motores

El LLM no debe calcular por sí solo métricas clínicas, decidir niveles de riesgo ni ejecutar escalados. Esas funciones deben residir en servicios deterministas o modelos versionados. El LLM recibe resultados estructurados, explica sus límites, formula preguntas y presenta opciones.

7.2 Patrón de orquestación recomendado

La conversación funciona como un orquestador con herramientas: consulta datos permitidos, solicita análisis, recupera planes, aplica políticas y redacta una respuesta. Cada llamada queda registrada con finalidad, versión y resultado. La salida final pasa por un filtro de seguridad independiente.

8. Modelo longitudinal del usuario

8.1 Componentes de memoria

Memoria	Contenido	Persistencia	Regla
Preferencias	Tono, horario, objetivos, accesibilidad.	Hasta revocación.	Confirmada por el usuario.
Hechos confirmados	Tratamientos, diagnósticos declarados, antecedentes.	Versionada.	No inferir ni completar.
Baseline conductual	Rangos personales y estacionalidad.	Recalculable.	Siempre con ventana y calidad.
Estado reciente	Variables de días/semanas.	Temporal.	Caduca o se resume.
Episodios y eventos	Periodos relevantes confirmados.	Longitudinal.	Etiquetado humano cuando sea posible.
Planes	Señales, acciones, contactos, preferencias.	Hasta reemplazo.	Aprobación explícita.
Inferencias	Hipótesis generadas por modelos.	Limitada y versionada.	Nunca fusionar con hechos.

8.2 Baseline personal

El baseline no es una media única. Debe representar distribuciones personales condicionadas por día de semana, estación, turnos, ciclo vital y contexto. También debe registrar la estabilidad del dato y la proporción de observaciones disponibles.

- Ventana inicial provisional, ajustable según densidad de datos.
- Actualización robusta que evite incorporar automáticamente periodos de crisis al “nuevo normal”.
- Versiones históricas para explicar por qué cambió una alerta.
- Capacidad de congelar o recalibrar el baseline con supervisión.
- Distinción entre baseline conductual, baseline subjetivo y objetivos deseados.

8.3 Firma individual de cambio

A medida que existan episodios confirmados, el sistema puede aprender qué señales precedieron, acompañaron o siguieron a cada episodio. Esta “firma” debe representarse como una hipótesis probabilística con soporte y no como una regla fija.

9. Fuentes de datos y fenotipado digital

Cada fuente debe justificarse por una pregunta concreta. La mera disponibilidad técnica no legitima su uso. La primera versión debería priorizar datos de alta interpretabilidad y baja intrusión.

Fuente	Variables posibles	Riesgos	Prioridad inicial
Autorregistro	Estado de ánimo, ansiedad, sueño, medicación, eventos.	Carga, sesgo de recuerdo.	Alta
Calendario	Regularidad, carga, reuniones, cancelaciones.	Contexto incompleto, privacidad relacional.	Media
Wearable	Sueño, actividad, frecuencia cardiaca, ritmos.	Precisión variable, sobrerinterpretación.	Media
Tareas/productividad	Finalización, aplazamientos, cambios de contexto.	Confundir rendimiento con bienestar.	Baja-media
Lenguaje conversacional	Temas, tono, complejidad, urgencia.	Sesgos lingüísticos, privacidad.	Alta dentro de la app
Correo/mensajería	Volumen, latencia, interacción.	Muy intrusivo; terceros afectados.	Baja
Localización	Movilidad y regularidad.	Alto impacto de privacidad.	No inicial
Datos clínicos	Escalas, diagnósticos, tratamiento.	Sensibilidad y gobernanza.	Sólo con marco clínico

Regla de producto
No introducir una fuente de datos hasta demostrar que añade utilidad incremental, que el usuario comprende su uso y que existen medidas específicas contra interpretaciones erróneas.

10. Variables y diccionario de características

10.1 Familias de variables

Ritmos y sueño

Duración estimada, regularidad de acostarse y levantarse, fragmentación, desfase social, variabilidad semanal.

Actividad y funcionamiento

Movilidad, actividad física, tareas completadas, carga percibida, abandono o sobreimplicación.

Interacción social

Frecuencia, diversidad, reciprocidad, cancelaciones, aislamiento autorreportado.

Lenguaje

Valencia, activación, rumiación, urgencia, coherencia, cambios de longitud y complejidad.

Autocuidado y tratamiento

Adherencia declarada, rutinas, uso de estrategias, contacto profesional.

Contexto

Duelo, conflicto, enfermedad, viajes, turnos, eventos vitales, cambios de medicación confirmados.

10.2 Requisitos del Feature Store

- Definición matemática y clínica de cada variable.
- Unidad, frecuencia, ventanas y tratamiento de faltantes.

- Fuente, consentimiento y calidad.
- Versión del algoritmo de cálculo.
- Rangos plausibles y reglas de exclusión.
- Relación con salidas, alertas y explicaciones.

11. Motor temporal y detección de cambios

El material de partida propone Z-score, IQR y estadísticas móviles. Son métodos interpretables adecuados para prototipos, pero deben integrarse en un marco temporal más amplio y evaluarse con datos reales.

Método	Utilidad	Limitación	Fase
Z-score	Desviación respecto a distribución de referencia.	Sensibilidad a no normalidad y outliers.	Prototipo
IQR	Detección robusta de extremos.	Ignora orden temporal.	Prototipo
Rolling Z-score	Cambio reciente frente a ventana local.	Dependencia de ventana y datos faltantes.	Prototipo
EWMA/CUSUM	Cambios graduales y acumulativos.	Requiere ajuste de sensibilidad.	Investigación
Descomposición estacional	Separar tendencia, ciclos y residuo.	Necesita series suficientes.	Investigación
Puntos de cambio bayesianos	Cambios de régimen con incertidumbre.	Mayor complejidad y validación.	Investigación
Modelos de estado	Estados latentes y transiciones.	Riesgo de sobreinterpretación.	Posterior

11.1 Detección multivariable

Las alertas no deberían depender de una única señal. El sistema debe distinguir convergencia, contradicción y ausencia de datos. Por ejemplo, una reducción de sueño junto con aumento de actividad y aceleración lingüística constituye un patrón diferente de la reducción de sueño con fatiga y baja actividad.

11.2 Secuencias

Debe conservarse el orden de eventos y evaluar ventanas temporales: señal antecedente, señal concurrente y resultado confirmado. Las secuencias aprendidas de la persona pueden compararse con episodios previos mediante métodos simples antes de explorar técnicas más complejas.

12. Personalidad, rasgos y estado psicológico

Los rasgos de personalidad pueden aportar contexto, pero no deben constituir el núcleo predictivo. Se utilizarán, si se validan, como variables de apoyo, preferentemente mediante instrumentos explícitos y no sólo inferidos de datos conductuales.

Constructo	Uso permitido	Uso no recomendado
Big Five	Preferencias generales, hipótesis de interacción, investigación.	Diagnóstico o explicación causal de recaídas.
Afrontamiento	Personalización de estrategias y barreras.	Etiquetado rígido de la persona.
Regulación emocional	Selección de ejercicios y seguimiento.	Inferencia exclusiva desde tono lingüístico.
Resiliencia y apoyos	Identificación de factores protectores.	Responsabilizar al usuario del empeoramiento.
Apego/estilo interpersonal	Contexto terapéutico si es relevante.	Perfil automático oculto.
MBTI	No prioritario.	Decisiones clínicas o predicción.

Decisión marco

El sistema debe distinguir rasgo, estado, contexto y función. Un cambio agudo no redefine la personalidad; un rasgo no determina el riesgo actual.

13. Motor de riesgo y estimación de incertidumbre

13.1 Salida estructurada

La salida interna no debe limitarse a "bajo/medio/alto". Debe incluir objetivo predicho, horizonte temporal, probabilidad o puntuación calibrada cuando exista, intervalo o nivel de incertidumbre, calidad de datos, principales contribuciones y alternativas explicativas.

Campo	Ejemplo conceptual
Evento objetivo	Deterioro funcional relevante definido por protocolo.
Horizonte	Próximos 7 días.
Estimación	Puntuación 0,62; no equivalente a probabilidad clínica hasta calibración.
Confianza	Baja-media por sólo dos fuentes y datos incompletos.
Contribuciones	Sueño irregular, cancelaciones y empeoramiento subjetivo.
Contradicciones	Actividad física conservada.
Acción	Confirmar estado, revisar plan y ofrecer contacto profesional.

13.2 Enfoque escalonado

Nivel	Descripción	Respuesta
0	Sin cambio relevante o datos insuficientes.	Información descriptiva; no alertar.
1	Desviación leve y aislada.	Check-in opcional y autocuidado.
2	Patrón persistente o convergente.	Revisión de plan y recomendación de apoyo.
3	Riesgo elevado o deterioro confirmado.	Contacto profesional según plan.
4	Señales de crisis o peligro inmediato.	Protocolo de emergencia independiente y localizado.

Los criterios concretos deben definirse por población y contexto. La clasificación no puede basarse exclusivamente en el LLM ni utilizarse sin validación.

14. Seguridad clínica y gestión de crisis

La seguridad debe ser un subsistema independiente, con reglas deterministas, contenidos localizados y supervisión. El flujo de crisis no puede depender de la disponibilidad, creatividad o interpretación del modelo generativo.

14.1 Componentes mínimos

- Detección de expresiones de autolesión, suicidio, violencia, abuso o incapacidad grave con sensibilidad y revisión.
- Preguntas de clarificación breves y no culpabilizadoras cuando sean seguras.
- Recursos de emergencia y atención urgente adaptados a localización y contexto.
- Plan de seguridad previamente acordado, cuando exista.
- Reglas de contacto con terceros sólo bajo consentimiento o base jurídica aplicable.
- Registro de incidentes, falsos positivos, falsos negativos y acciones ejecutadas.
- Derivación humana para revisión de casos y mejora del protocolo.

14.2 Fallos a evitar

- Mensajes alarmistas ante lenguaje ambiguo.
- Promesas de confidencialidad absoluta.
- Afirmar que el sistema "sabe" que habrá una recaída.
- Dar instrucciones terapéuticas complejas durante una crisis.
- Bloquear la conversación sin ofrecer opciones claras de ayuda.
- Contactar a terceros sin reglas transparentes.

15. Motor de recomendaciones e intervenciones

Las recomendaciones deben seleccionarse por problema observable, preferencias, contraindicaciones, esfuerzo requerido y evidencia disponible. No deben presentarse como tratamiento prescrito por la IA.

Categoría	Ejemplos	Condición
Autorregulación	Respiración, grounding, pausa, tolerancia al malestar.	Baja intensidad y consentimiento.
Activación conductual	Microtarear, exposición gradual a rutinas, planificación.	Objetivos definidos y seguimiento.
Sueño y ritmos	Regularidad, luz, reducción de activación nocturna.	Evitar recomendaciones rígidas o culpabilizadoras.
ACT/CBT/DBT	Defusión, registro de pensamiento, solución de problemas, habilidades.	Contenido revisado por profesionales.
Apoyo social	Contactar persona elegida, preparar conversación.	Privacidad y preferencias.
Atención profesional	Preparar consulta, solicitar cita, compartir resumen.	Recomendación prioritaria cuando proceda.

15.1 Política de selección

- Máximo de una a tres acciones por interacción.
- Explicar por qué se propone cada acción.
- Permitir rechazar, posponer o sustituir.
- Registrar utilidad percibida y carga.
- No insistir en estrategias repetidamente ineficaces.
- Distinguir recomendaciones generales de planes acordados con un profesional.

16. Arquitectura LLM, RAG y agentes

16.1 Funciones apropiadas del LLM

- Comprender lenguaje natural y objetivos.
- Formular preguntas de aclaración.
- Sintetizar datos estructurados en lenguaje comprensible.
- Recuperar contenidos aprobados y adaptar su presentación.
- Ayudar a preparar planes, diarios y resúmenes.
- Detectar ambigüedades para activar componentes especializados.

16.2 Funciones que deben permanecer fuera del LLM

- Cálculo de métricas y umbrales.
- Persistencia de hechos clínicos sin confirmación.
- Decisión final de nivel de riesgo.
- Ejecución automática de contactos de emergencia.
- Modificación de consentimiento o permisos.
- Generación libre de recomendaciones clínicas no revisadas.

16.3 RAG clínico-controlado

La recuperación aumentada debe consultar una base de conocimiento curada, versionada y etiquetada por población, objetivo, nivel de evidencia, contraindicaciones y fecha de revisión. La respuesta debe poder rastrear qué contenido se recuperó y qué adaptación realizó el modelo.

16.4 Prompting y políticas

Bloque	Contenido
Rol	Asistente de apoyo y explicación; límites explícitos.
Contexto	Datos permitidos, ventana temporal, calidad y preferencias.
Política	Reglas de seguridad, no diagnóstico, escalado y privacidad.
Herramientas	Contratos claros, entradas estructuradas y permisos.
Salida	Esquema validado antes de convertir a lenguaje natural.
Evaluación	Casos de prueba, red teaming y monitorización por versión.

17. Modelo de datos conceptual

Entidad	Campos esenciales	Notas
User	id pseudónimo, zona horaria, configuración.	Identidad separada de datos clínicos.
ConsentGrant	fuelle, finalidad, alcance, vigencia, versión.	Revocable y auditable.
Observation	tipo, valor, unidad, timestamp, fuente, calidad.	Dato observado, no inferencia.
Feature	nombre, valor, ventana, algoritmo, versión.	Derivada reproducible.
Baseline	feature, distribución, contexto, periodo, estabilidad.	Versionado.
Event	tipo, fechas, confirmación, contexto.	Episodios y eventos vitales.
Inference	objetivo, puntuación, incertidumbre, evidencia, modelo.	Caducidad definida.
Plan	señales, acciones, contactos, aprobaciones.	Control del usuario/profesional.
Intervention	contenido, motivo, respuesta, utilidad.	Aprendizaje de preferencias.
AuditEvent	actor, acción, finalidad, resultado.	Immutable y minimizado.

17.1 Reglas de integridad semántica

- Toda observación conserva procedencia y timestamp.
- Toda inferencia referencia las observaciones y features que la sustentan.
- Los hechos confirmados no se sobrescriben con inferencias.
- La ausencia de datos se representa explícitamente.
- Las correcciones del usuario generan una nueva versión y no borran la trazabilidad.
- Los datos de terceros deben minimizarse o anonimizarse.

18. APIs y contratos de servicio

Los contratos deben diseñarse antes que las implementaciones para mantener modularidad. A continuación se proponen interfaces conceptuales, no especificaciones definitivas.

Ingesta de observaciones

```
POST /observations
{user_id, source, type, value, unit, timestamp, consent_id, quality}
```

Cálculo temporal

```
POST /analytics/run
{user_id, feature_set, window, baseline_version}
```

Consulta de estado

```
GET /state/{user_id}?window=30d
→ observations_summary, features, uncertainty, missingness
```

Evaluación de seguridad

```
POST /safety/evaluate
{text, structured_state, locale, plan_id}
```

Generación de explicación

```
POST /explanations/generate
{inference_id, audience, detail_level, language}
```

19. Privacidad, seguridad y gobernanza

19.1 Controles arquitectónicos

Control	Aplicación
Minimización	Recoger sólo variables justificadas por una finalidad.
Separación	Identidad, datos sensibles, analítica e investigación en dominios separados.
Cifrado	En tránsito y reposo, con gestión de claves y rotación.
Acceso	Mínimo privilegio, autenticación fuerte y revisión periódica.

Retención	Plazos por tipo de dato; eliminación verificable.
Exportación	Formato comprensible y portable.
Auditoría	Acceso, cambios, modelos, prompts, alertas y compartición.
Entornos	Desarrollo y pruebas con datos sintéticos o desidentificados.

19.2 Gobernanza

- Comité clínico y de seguridad para protocolos y contenidos.
- Responsable de datos y privacidad con capacidad de veto.
- Proceso de cambio para modelos, prompts y umbrales.
- Registro de riesgos y decisiones de diseño.
- Canal de incidentes y comunicación a usuarios.
- Mecanismo de impugnación y corrección de inferencias.

El análisis jurídico y regulatorio debe realizarse por jurisdicción y caso de uso antes de cualquier despliegue. Este documento no sustituye asesoramiento legal ni determina una clasificación regulatoria.

20. Observabilidad, evaluación y calidad

20.1 Métricas técnicas

- Disponibilidad y latencia por servicio.
- Cobertura y calidad de datos.
- Errores de conectores y sincronización.
- Drift de features y modelos.
- Tasa de fallos de esquema y alucinaciones detectadas.
- Trazabilidad completa de explicaciones.

20.2 Métricas de seguridad y utilidad

Dimensión	Métricas candidatas
Seguridad	Falsos negativos/positivos en crisis, incidentes, escalados inapropiados.
Comprensión	Capacidad del usuario para explicar qué observó el sistema y con qué límites.
Aceptabilidad	Retención, carga, control percibido, confianza calibrada.
Utilidad	Acciones completadas, preparación de consulta, detección anticipada confirmada.
Equidad	Rendimiento y errores por idioma, edad, género, contexto y accesibilidad.
Clínica	Resultados definidos en protocolos y estudios; no inferidos sólo de engagement.

20.3 Evaluación del LLM

- Batería de casos normales, ambiguos, adversariales y de crisis.
- Evaluación humana por clínicos y usuarios.
- Pruebas de privacidad y revelación indebida.
- Consistencia entre idiomas y estilos de comunicación.
- Revisión tras cada cambio de modelo o prompt.
- Shadow mode antes de activar acciones.

21. Estrategia de validación clínica y científica

La evidencia debe construirse en capas. El objetivo inicial es demostrar que el sistema mide y comunica de forma segura; sólo después se evaluará si predice o mejora resultados.

Etap	Pregunta	Diseño posible
1. Validez de contenido	¿Las variables y explicaciones son clínicamente razonables?	Panel de expertos y entrevistas.
2. Validez analítica	¿Las métricas se calculan de forma fiable?	Datos sintéticos y datasets retrospectivos.
3. Usabilidad y seguridad	¿Se entiende y evita daño?	Estudios de tareas y simulación.
4. Validez concurrente	¿Se relaciona con medidas reconocidas?	Estudio observacional.
5. Predicción	¿Anticipa un evento definido y calibrado?	Cohorte prospectiva.
6. Impacto	¿Mejora decisiones o resultados?	Ensayo pragmático o diseño escalonado.

21.1 Definición de eventos

Antes de entrenar un modelo predictivo es imprescindible definir qué significa "recaída", quién la confirma, durante qué ventana, con qué severidad y qué alternativas deben excluirse. Diferentes trastornos y contextos requieren objetivos distintos.

22. Arquitectura técnica de referencia

La arquitectura concreta se elegirá más adelante. Como patrón de referencia se propone una plataforma orientada a servicios, eventos y datos versionados, con límites claros entre dominio clínico, analítica e interfaz.

Plano	Componentes
Experiencia	Aplicación móvil/web, chat, visualización longitudinal, consentimientos.
API y orquestación	API gateway, autorización, workflow engine, rate limits.
Dominio	Usuarios, planes, observaciones, profesionales, intervenciones.
Datos	Base transaccional, time-series store, object store, feature store.
IA/ML	Pipelines, registry, inference services, RAG, evaluation.
Seguridad	IAM, KMS, secrets, audit log, SIEM, DLP.
Operaciones	CI/CD, observabilidad, backups, incident response.

22.1 Preferencias de diseño

- Interfaces contract-first y esquemas estrictos.
- Procesamiento asíncrono para series y conectores.
- Idempotencia y reconciliación de datos.
- Versionado de features, modelos, prompts y contenidos.
- Capacidad de despliegue regional y separación por tenant cuando proceda.
- Fallback seguro cuando un servicio o modelo no está disponible.

23. Roadmap de desarrollo por pasos

El proyecto se plantea como una secuencia de decisiones y experimentos. Cada fase debe tener criterios explícitos de entrada, salida y abandono.

Fase	Objetivo	Entregables	Criterio de salida
0. Alineación	Delimitar problema, población y riesgos.	Charter, mapa de actores, registro de riesgos.	Problema priorizado y patrocinio.
1. Descubrimiento	Comprender necesidades y flujos reales.	Entrevistas, journeys, prototipos conceptuales.	Necesidad y aceptabilidad preliminar.
2. Núcleo de autocuidado	Construir check-ins, diario y resumen.	MVP sin predicción, consentimiento y auditoría.	Usabilidad y seguridad.
3. Baseline y tendencias	Añadir series personales y visualización.	Feature store v1, métodos simples, explicaciones.	Validez analítica.
4. Prevención personalizada	Planes, anomalías y recomendaciones.	Motor de reglas, feedback y escalado.	Baja tasa de daño y utilidad.
5. Colaboración clínica	Panel y resúmenes compartidos.	Roles, permisos, workflow profesional.	Aceptabilidad clínica.
6. Investigación predictiva	Modelos por evento y población.	Protocolos, datasets, calibración.	Evidencia prospectiva.

7. Escalado	Robustez, operaciones y cumplimiento.	Plataforma productiva y gobernanza madura.	Go/no-go regulado.
-------------	---------------------------------------	--	--------------------

24. Backlog inicial de épicas

Épica	Resultado	Prioridad
E1 Consentimiento y control	Permisos por fuente y finalidad; revocación; historial.	Crítica
E2 Check-in y diario	Captura subjetiva configurable y accesible.	Crítica
E3 Perfil y baseline	Rangos personales, contexto y recalibración.	Alta
E4 Timeline	Visualización de observaciones, eventos e intervenciones.	Alta
E5 Motor temporal	Rolling stats, IQR, Z-score y calidad.	Alta
E6 Explicaciones	Evidencia, incertidumbre y alternativas.	Crítica
E7 Plan preventivo	Señales, acciones y contactos acordados.	Alta
E8 Seguridad	Crisis, escalado, localización y auditoría.	Crítica
E9 RAG de contenidos	Biblioteca curada y versionada.	Media
E10 Panel profesional	Compartición selectiva y revisión.	Posterior
E11 Evaluación	Casos de prueba, métricas y experimentos.	Crítica
E12 Operaciones	Observabilidad, incidentes y gestión de versiones.	Alta

25. Riesgos principales y mitigaciones

Riesgo	Consecuencia	Mitigación de diseño
Falsas alarmas	Ansiedad, fatiga y abandono.	Umbral es graduados, confirmación y aprendizaje de feedback.
Falsa tranquilidad	Retraso de atención.	Nunca afirmar ausencia de riesgo; rutas claras a ayuda.
Sesgo de datos	Rendimiento desigual.	Evaluación por subgrupos y datos faltantes explícitos.
Vigilancia percibida	Pérdida de autonomía.	Consentimiento granular y modo privado/local.
Sobredependencia	Sustitución de relaciones humanas.	Límites, promoción de apoyos y diseño no adictivo.
Alucinación del LLM	Información falsa o peligrosa.	RAG, esquemas, filtros y contenido aprobado.
Brecha de datos	Daño reputacional y personal.	Minimización, cifrado, segregación e incident response.
Deriva de propósito	Usos no previstos.	Gobernanza, contratos de finalidad y auditoría.
Modelo no calibrado	Interpretaciones incorrectas.	Shadow mode, calibración y validación prospectiva.
Ambición excesiva	Proyecto inmanejable.	Fases, criterios de salida y límites de alcance.

26. Preguntas abiertas que deben resolverse

- ¿Cuál es la población inicial: población general, trastorno concreto, seguimiento postalta u otro escenario?
- ¿Qué evento o resultado se desea prevenir o detectar y quién lo confirma?
- ¿La primera versión será de autocuidado, investigación o colaboración clínica?
- ¿Qué fuentes aportan valor suficiente para justificar su intrusión?
- ¿Qué profesional o comité aprobará contenidos, protocolos y escalados?
- ¿Qué nivel de personalización puede ofrecerse sin crear perfiles opacos?
- ¿Cómo se medirá la utilidad para el usuario más allá de la retención?
- ¿Qué datos pueden procesarse localmente en el dispositivo?
- ¿Qué partes del sistema requieren explicaciones individualizadas y cuáles reglas fijas?
- ¿Qué criterios obligan a detener una función o un piloto?

27. Decisiones recomendadas para el próximo ciclo

1. Definir un único escenario inicial y una población concreta.
2. Crear un mapa de riesgos clínicos y de privacidad antes de construir conectores.
3. Diseñar un prototipo de onboarding, check-in, timeline y revisión semanal sin predicción.
4. Construir el esquema de datos de Observation, Feature, Baseline, Inference y Plan.
5. Implementar métodos temporales simples con datos sintéticos y explicaciones visibles.
6. Definir un protocolo de seguridad independiente del LLM.
7. Constituir un pequeño grupo asesor clínico, de usuarios y privacidad.
8. Preparar un plan de evaluación con criterios de abandono y no sólo de éxito.

Resultado esperado del siguiente ciclo
Un prototipo seguro y comprensible que demuestre la arquitectura longitudinal y permita aprender qué datos y explicaciones son realmente útiles. No se necesita aún un predictor de recaídas.

28. Apéndice A — Esquema de salida analítica

```
{
  "analysis_id": "uuid",
  "user_id": "pseudonymous-id",
  "window": { "start": "...", "end": "..."},
  "target": "defined_event_or_state",
  "status": "descriptive|signal|escalation",
  "score": null,
  "uncertainty": { "level": "high", "reasons": [ "missing_data" ] },
  "evidence": [
    { "feature": "sleep_regularity", "change": -0.32, "baseline_version": "v3" }
  ],
  "contradictions": [],
  "alternative_explanations": [ "travel", "shift_work" ],
  "recommended_actions": [ "confirm_context", "review_plan" ],
  "model_version": "...",
  "policy_version": "..."
}
```

29. Apéndice B — Pseudocódigo del pipeline

```
function analyze(user, window):
  consent = load_active_consent(user)
  observations = ingest_allowed_sources(consent, window)
  normalized = normalize_time_and_quality(observations)
  features = compute_versioned_features(normalized)
  baseline = load_or_update_baseline(user, features)
  deviations = detect_univariate_and_multivariate_changes(features, baseline)
  context = retrieve_confirmed_context(user, window)
  safety = safety_engine.evaluate(observations, context)
  if safety.requires_escalation:
    return execute_safety_protocol(safety, user.plan)
  inference = risk_engine.evaluate(deviations, context, data_quality)
  explanation = explanation_service.render(inference, audience=user)
  actions = recommendation_engine.select(inference, user.preferences, user.plan)
  log_audit_and_feedback(...)
  return {explanation, actions, uncertainty}
```

30. Apéndice C — Criterios de “Definition of Done”

Componente	No se considera terminado hasta que...
Fuente de datos	Tiene finalidad, consentimiento, calidad, borrado y evaluación de intrusión.
Feature	Está definida, versionada, probada y explicable.
Modelo	Tiene dataset, objetivo, métricas, calibración, subgrupos y rollback.
Prompt	Tiene casos de prueba, política, versionado y evaluación humana.
Alerta	Tiene umbral, justificación, respuesta, escalado y medida de daño.
Intervención	Está revisada, tiene contraindicaciones y feedback de utilidad.

Pantalla	Es accesible, comprensible y permite corrección o rechazo.
Release	Supera pruebas de seguridad, privacidad, observabilidad y rollback.

31. Conclusión

PsychApp debe desarrollarse como una infraestructura de aprendizaje longitudinal y apoyo seguro, no como un chatbot que improvisa diagnósticos. La arquitectura propuesta centra el proyecto en datos consentidos, comparación intraindividual, separación entre hechos e inferencias, incertidumbre explícita, intervención proporcionada y supervisión humana.

El documento ofrece una base para avanzar por pasos. Su función es reducir ambigüedad, ordenar decisiones y evitar que la ambición técnica preceda a la definición clínica. Cada módulo deberá concretarse mediante investigación, prototipos y validación antes de convertirse en producto.

Próximo hito	Convertir este marco en un paquete de descubrimiento: escenario inicial, arquitectura mínima, mapa de datos, prototipo de experiencia, protocolo de seguridad y plan de evaluación.
--------------	---

